HURTOWNIE DANYCH I SYSTEMY BUSINESS INTELLIGENCE

Politechnika Warszawska · Wydział Matematyki i Nauk Informacyjnych

KM2 — Raport Wstępny

Architektura systemu, model przetwarzania i składowania danych

Climate, Economy and Mental Health in Europe (2000–2010)

Wpływ warunków klimatycznych i czynników ekonomicznych na zdrowie psychiczne populacji europejskiej w latach 2000-2010

Liwia Jankowska · Wiktoria Kawa · Wojciech Łukaszyk

1. Cel systemu i korzyści biznesowe

Projekt ma na celu budowę systemu klasy DW/BI, który integruje dane o warunkach klimatycznych, wskaźnikach ekonomicznych oraz o rozpowszechnieniu zaburzeń psychicznych dla 40 krajów europejskich w latach 2000–2010. System dostarcza narzędzie analityczne dla organizacji zajmujących się ochroną zdrowia oraz dla decydentów w zakresie polityki zdrowotnej.

1.1 Pytania analityczne

Pytanie analityczne	Opis
Korelacja klimat–depresja	Czy kraje z mniejszą ilością słońca zimą wykazują wyższą prevalencję depresji i zaburzeń afektywnych sezonowych (SAD)?
Wpływ PKB na zdrowie	Czy wyższy PKB per capita i większe wydatki na ochronę zdrowia niwelują negatywny wpływ klimatu na zdrowie psychiczne?
Bezrobocie a alkohol	Czy wyższe bezrobocie koreluje z wyższym spożyciem alkoholu – jako mechanizmem radzenia sobie ze stresem ekonomicznym?
Trendy 2000–2010	Jak zmieniała się prevalencja poszczególnych zaburzeń psychicznych w Europie w ciągu dekady?
Klasyfikacja Köppena	Czy typ klimatu (Csa, Cfb, Dfb, Dfc) systematycznie różnicuje wskaźniki zdrowia psychicznego?

1.2 Korzyści dla użytkownika końcowego

Odbiorca: analityk ochrony zdrowia lub decydent polityki zdrowotnej. Narzędzie: interaktywny dashboard Power BI z dynamicznym filtrowaniem według stref klimatycznych, nasłonecznienia i wskaźników ekonomicznych.

- Identyfikacja korelacji między brakiem nasłonecznienia a rozpowszechnieniem depresji i zaburzeń lękowych.
- Prognozowanie zapotrzebowania na opiekę psychiatryczną w oparciu o trendy klimatyczne i ekonomiczne.
- Optymalizacja alokacji środków budżetowych na profilaktykę chorób psychicznych w regionach klimatycznie trudnych.
- Analiza skuteczności wydatków zdrowotnych: czy bogactwo kraju niweluje negatywny wpływ klimatu?
- Nawigacja w hierarchii zaburzeń (ICD-10) — od poziomu kategorii do konkretnej jednostki chorobowej.

2. Architektura rozwiązania

System zbudowany jest jako pięciowarstwowa architektura ELT, w której każda warstwa ma wyraźnie zdefiniowane obowiązki. Dane przepływają jednostronnie od źródeł przez warstwę ekstrakcji i transformacji do hurtowni, skąd są prezentowane w warstwie raportowej.

Warstwa	Komponenty	Rola
1 — Źródła	Open-Meteo API, World Bank API, OWID/IHME CSV, WHO GHED CSV	Zewnętrzne dane historyczne 2000–2010; wszystkie bezpłatne
2 — Ekstrakcja	Python (requests, pandas) → SQL Server schema: staging	Skrypty extract_*.py pobierają dane i zapisują do tabel staging.*
3 — Transformacje (ETL)	SSIS / ADF lub dbt + Python	Czyszczenie, standaryzacja, budowanie wymiarów (SCD2) i tabel faktowych; testy jakości
4 — Hurtownia	SQL Server schema: dw	Schemat konstelacji: 3 tabele faktowe + 5 wymiarów + 3 agregaty pogodowe (VIEW)
5 — Raportowanie	Power BI Desktop / Service	Dashboard z mapami EU, drill-down, scatter plots, what-if analysis

2.1 Uzasadnienie wyboru narzędzi

Narzędzie	Uzasadnienie wyboru
ETL Tool (SSIS / ADF lub dbt)	SSIS i Azure Data Factory to profesjonalne narzędzia ETL standardowo stosowane w produkcyjnych hurtowniach danych. dbt jest alternatywą open-source z wbudowanymi testami jakości i pełną automatyzacją pipeline. Wybór narzędzia ETL nie wpływa na pozostałe warstwy architektury.
Microsoft SQL Server	Dwa schematy: staging (surowe dane) oraz dw (hurtownia). Pełna integracja z Power BI. Wsparcie SCD2 przez MERGE.
Power BI	Import Mode dla wymiarów i agregatów (szybkość). DirectQuery dla FACT_WEATHER (~146 000 wierszy). Hierarchie OLAP, parametry what-if, mapy Europy.
Open-Meteo Historical API	Zastąpił Meteostat (KM1) — brak klucza API, brak limitów dla danych historycznych, format JSON, zakres od 1940 r.

3. Opis wykorzystywanych zbiorów danych

System integruje sześć niezależnych źródeł danych o różnych formatach i metodach dostępu. Zakres czasowy to pełnych 11 lat: 2000–2010. Zakres geograficzny ograniczony do 40 krajów europejskich.

Źródło	Format	Dostęp	Odświeżanie	Opis i uwagi
Open-Meteo Historical API	REST/JSON	Publiczny, bez klucza archive-api.open-meteo.com	Jednorazowe (hist.)	Temp. min/maks/śr., opady, nasłonecznienie [s→h], zachmurzenie, wiatr. Wywołanie per stolica kraju.
World Bank API (GDP, Unemployment)	REST/JSON	Publiczny, bez klucza api.worldbank.org/v2/	Jednorazowe	PKB per capita (NY.GDP.PCAP.CD), stopa bezrobocia (SL.UEM.TOTL.ZS). ~5% braków dla małych krajów.

Źródło	Format	Dostęp	Odświeżanie	Opis i uwagi
World Bank API (Health Exp.)	REST/JSON	Publiczny, bez klucza	Jednorazowe	Wydatki na ochronę zdrowia per capita (SH.XPD.CHEX.PC.CD). ~90% pokrycia EU-40.
OWID / IHME GBD (Mental Health)	CSV GitHub	Publiczny raw.githubusercontent.com	Jednorazowe	~12 zaburzeń per kraj per rok: prevalencja [% pop.] i DALYS/100k. Dane to estymaty modelowe IHME.
OWID Alcohol Consumption	CSV GitHub	Publiczny raw.githubusercontent.com	Jednorazowe	Spożycie alkoholu per capita [l/os./rok]. 38/40 krajów EU.
Beck et al. 2018 (Köppen)	Tabela ręczna	Jednorazowe (statyczne)	SCD0 — stałe	Ręczne przypisanie klasyfikacji Köppena dla 40 krajów europejskich. Nie ulega zmianie.

Ograniczenie:	Dane pogodowe pobierane są per stolica kraju (capitol-proxy assumption). Dla dużych krajów (Francja, Polska, Szwecja) klimat wewnętrzny jest niejednorodny. Kompromis akceptowalny na poziomie projektu — można rozszerzyć do średnich z 3–5 stacji per kraj.

4. Planowany proces ETL/ELT

Proces realizowany jest w podejściu ELT: dane ładowane są w formie surowej do warstwy staging, a następnie transformowane w narzędziu ETL przez trzy warstwy: staging, intermediate i marts. Narzędzie ETL (SSIS / ADF / dbt) odpowiada za orkiestrację przeprzepływu, czyszczenie i ładowanie danych do schema dw.

4.1 Warstwy przetwarzania

Warstwa	Modele / Kroki	Opis transformacji
staging	stg_weather stg_economy stg_mental_health stg_country	Zmiana nazw kolumn, rzutowanie typów, filtr lat 2000–2010 i krajów EU-40. Unifikacja źródeł ekonomicznych przez JOIN na country_code i year.
intermediate	int_country_scd2 int_weather_agg_monthly int_disorder_list	SCD2 snapshot dla INCOME_GROUP. Wstępna agregacja pogody do poziomu miesięcznego. Ekstrakcja listy zaburzeń z uzupełnieniem ICD-10.
marts	dim_*.sql fact_*.sql	Finalne tabele hurtowni w schema dw. Lookup kluczów surogatowych. Odrzut rekordów bez dopasowania do reject table.

4.2 Kluczowe transformacje

Transformacja	Opis
Nasłonecznienie [s → h]	Open-Meteo zwraca SUNSHINE_DURATION w sekundach. Transformacja: ROUND(SUNSHINE_S / 3600.0, 2). Kolumna docelowa: SUNSHINE_H.

Transformacja	Opis
Standaryzacja nazw krajów	Tabela mapująca country_alias_map.csv; JOIN po znormalizowanym kodzie ISO2. Eliminuje rozbieżności np. "USA" vs "United States".
Braki danych (NULL)	NULL w tabeli faktowej; Power BI filtruje brakujące wartości. Dla trendów czasowych: interpolacja liniowa.
Pivot zaburzeń (IHME)	CSV IHME ma kolumny per zaburzenie → UNPIVOT do formatu długiego: jeden wiersz = kraj × rok × zaburzenie.
SCD Typ 2 (INCOME_GROUP)	Zmiana w DIM_COUNTRY: zamknięcie starego rekordu (VALID_TO = data, IS_CURRENT = 0) + INSERT nowego rekordu.
Filtr geograficzny	Tylko 40 krajów europejskich — lista kodów ISO2 propagowana przez modele downstream.

4.3 Testy jakości danych

Typ testu	Kolumna	Model	Cel
not_null	COUNTRY_KEY, YEAR_KEY	fact_economy, fact_mental_health	Brak NULL w kluczach FK
unique	WEATHER_KEY, DATE_KEY	fact_weather, dim_date	Unikalność PK
relationships	COUNTRY_KEY → DIM_COUNTRY	Wszystkie tabele faktowe	Integralność referencyjna
accepted_values	INCOME_GROUP	dim_country	Low / Lower-middle / Upper-middle / High
at_least_one	PREVALENCE_PCT	fact_mental_health	Brak całkowicie pustych krajów

5. Model hurtowni danych

Model zbudowany jako schemat konstelacji (Constellation Schema): trzy tabele faktowe współdzielą wymiar DIM_COUNTRY. Tabele faktowe o danych rocznych (FACT_ECONOMY, FACT_MENTAL_HEALTH) używają DIM_YEAR, a FACT_WEATHER o danych dziennych — DIM_DATE. Wszystkie trzy tabele faktowe są typu Periodic Snapshot, zgodnie z metodyką Kimballa.

5.1 Typy tabel faktowych i granulacja

Tabela faktowa	Typ (Kimball)	Granulacja	Wiersze	Klucz czasowy	Uzasadnienie
FACT_WEATHER	Periodic Snapshot	kraj × dzień	~146 000 (40 × 3 653)	DATE_KEY → DIM_DATE	Dzienny zapis stanu pogody per kraj. Osobna tabela zachowuje pełną rozdzielczość dzienną.
FACT_MENTAL_HEALTH	Periodic Snapshot	kraj × rok × zaburzenie	~5 280 (40 × 11 × 12)	YEAR_KEY → DIM_YEAR	Roczna migawka wskaźników chorobowości. Wym. DISORDER unikalny dla tej tabeli.
FACT_ECONOMY	Periodic Snapshot	kraj × rok	~440 (40 × 11)	YEAR_KEY → DIM_YEAR	Roczna migawka wskaźników ekonomicznych. Naturalny punkt JOIN z FACT_MENTAL_HEALTH.

5.2 Rozwiązanie problemu granulacji — agregaty pogodowe

Bezpośredni JOIN dziennego FACT_WEATHER z rocznym FACT_MENTAL_HEALTH spowodowałby duplikację każdego rocznego rekordu 365 razy. Rozwiązanie: trzy widoki SQL (VIEW), które wstępnie agregują dane pogodowe do wymaganej granulacji przed JOIN-em.

Agregat	Granulacja	Wiersze	JOIN z	Pytanie analityczne
AGG_WEATHER_MONTHLY	kraj × miesiąc	~5 280	DIM_MONTH	Jak zmieniała się temperatura i nasłonecznienie miesiąc po miesiącu? Drill-down w Power BI.
AGG_WEATHER_ANNUAL	kraj × rok	~440	FACT_ECONOMY FACT_MENTAL_HEALTH	Czy kraje z wyższym rocznym nasłonecznieniem mają niższą prevalencję depresji? Korelacja roczna.
AGG_WEATHER_SEASONAL	kraj × rok × pora roku	~1 760	FACT_MENTAL_HEALTH (filtr SEASON='Winter')	KLUCZOWY: czy długość ciemnej zimy koreluje z prevalencją SAD? Roczna średnia nie wystarcza.

5.3 Definicje tabel faktowych

FACT_WEATHER

Kolumna	Typ	Opis
WEATHER_KEY	INT PK	Surogatowy klucz główny (IDENTITY)
DATE_KEY	INT FK	Klucz do DIM_DATE (granulacja dzienna)
COUNTRY_KEY	INT FK	Klucz do DIM_COUNTRY
TEMP_AVG	DECIMAL(5,2)	Średnnia temperatura dzienna [°C]
TEMP_MIN	DECIMAL(5,2)	Minimalna temperatura dzienna [°C]
TEMP_MAX	DECIMAL(5,2)	Maksymalna temperatura dzienna [°C]
PRECIP_MM	DECIMAL(6,2)	Suma opadów [mm]
SUNSHINE_H	DECIMAL(5,2)	Czas nasłonecznienia [h]; API zwraca sekundy / 3600
CLOUD_COVER	DECIMAL(4,1)	Zachmurzenie [%]; zakres 0–100
WIND_SPEED	DECIMAL(5,2)	Prędkość wiatru [km/h]

FACT_MENTAL_HEALTH

Kolumna	Typ	Opis
MENTAL_HEALTH_KEY	INT PK	Surogatowy klucz główny (IDENTITY)
YEAR_KEY	INT FK	Klucz do DIM_YEAR
COUNTRY_KEY	INT FK	Klucz do DIM_COUNTRY
DISORDER_KEY	INT FK	Klucz do DIM_DISORDER
PREVALENCE_PCT	DECIMAL(6,4)	Współczynnik chorobowości [% populacji]
DALYS_PER_100K	DECIMAL(8,2)	Lata życia skorygowane niepełnosprawnością na 100 000

FACT_ECONOMY

Kolumna	Typ	Opis
ECONOMY_KEY	INT PK	Surogatowy klucz główny (IDENTITY)
YEAR_KEY	INT FK	Klucz do DIM_YEAR
COUNTRY_KEY	INT FK	Klucz do DIM_COUNTRY
GDP_PER_CAPITA_USD	DECIMAL(12,2)	PKB per capita [USD bieżące]; WB: NY.GDP.PCAP.CD

Kolumna	Typ	Opis
HEALTH_EXP_PER_CAPITA_USD	DECIMAL(10,2)	Wydatki na ochronę zdrowia per capita [USD]
HEALTH_EXP_PCT_GDP	DECIMAL(5,2)	Wydatki na zdrowie [% PKB]; zakres 0–100
ALCOHOL_LITERS_PER_CAPITA	DECIMAL(5,2)	Spożycie alkoholu [l czystego alkoholu/os./rok]
UNEMPLOYMENT_PCT	DECIMAL(5,2)	Stopa bezrobocia [% siły roboczej]

5.4 Wymiary — typy SCD

Wymiar	Typ SCD	Wiersze	Uwagi
DIM_COUNTRY	SCD Typ 2	40 (+hist.)	INCOME_GROUP ulega SCD2 — nowy rekord z VALID_FROM/VALID_TO/IS_CURRENT. CLIMATE_TYPE statyczny (SCD0).
DIM_DISORDER	SCD Typ 1	12	Ewentualna korekta = UPDATE. Kolumny ICD10_CODE, IS_SEASONAL, TREATMENT_TYPE to dane syntetyczne.
DIM_DATE	SCD Typ 0	3 653	Wygenerowany jednorazowo dla 2000-01-01 do 2010-12-31. Hierarchia: rok → kwartał → miesiąc → dzień.
DIM_YEAR	SCD Typ 0	11	Ręczny INSERT dla 2000–2010. Hierarchia: dekada → rok. FK w FACT_ECONOMY i FACT_MENTAL_HEALTH.
DIM_MONTH	SCD Typ 0	132	Generowany CTE dla 2000-01 do 2010-12. Używany wyłącznie przez AGG_WEATHER_MONTHLY.

6. Kluczowe miary i atrybuty modelu

6.1 Miary ilościowe (tabele faktowe)

Miara	Tabela	Typ danych	Opis i rola analityczna
PREVALENCE_PCT	FACT_MENTAL_HEALTH	DECIMAL(6,4)	Współczynnik chorobowości [% populacji]. Kluczowa miara projektu — zmienna objaśniana w analizach korelacyjnych.
DALYS_PER_100K	FACT_MENTAL_HEALTH	DECIMAL(8,2)	Lata życia skorygowane niepełnosprawnością na 100 000 mieszkańców. Uzupełniająca miara ciężaru choroby.
SUNSHINE_H	FACT_WEATHER	DECIMAL(5,2)	Czas nasłonecznienia dziennego [h]. Kluczowy predyktor w hipotezie projektu. Obliczany ze źródła [s] / 3600.
TEMP_AVG	FACT_WEATHER	DECIMAL(5,2)	Średnnia temperatura dzienna [°C]. Używana w AGG_WEATHER_SEASONAL do charakterystyki zimy.

Miara	Tabela	Typ danych	Opis i rola analityczna
GDP_PER_CAPITA_USD	FACT_ECONOMY	DECIMAL(12,2)	PKB per capita [USD bieżące]. Zmienna moderująca — czy bogactwo niweluje wpływ klimatu?
HEALTH_EXP_PER_CAPITA_USD	FACT_ECONOMY	DECIMAL(10,2)	Wydatki na ochronę zdrowia per capita [USD]. Korelat dostępu do usług psychiatrycznych.
ALCOHOL_LITERS_PER_CAPITA	FACT_ECONOMY	DECIMAL(5,2)	Spożycie alkoholu [l czystego alkoholu/os/rok]. Wskaźnik behawioralny — możliwy mediator.
UNEMPLOYMENT_PCT	FACT_ECONOMY	DECIMAL(5,2)	Stopa bezrobocia [% siły roboczej]. Wskaźnik stresu ekonomicznego populacji.

6.2 Kluczowe atrybuty wymiarów

Atrybut	Wymiar	Opis i rola analityczna
CLIMATE_TYPE	DIM_COUNTRY	Klasyfikacja Köppena (np. Cfb, Dfb, Csa, Dfc). Główny atrybut segmentacyjny — grupuje kraje według reżimu klimatycznego.
INCOME_GROUP	DIM_COUNTRY	Grupa dochodowa WB: Low / Lower-middle / Upper-middle / High. Podlega SCD2. Atrybut kontrolny.
REGION	DIM_COUNTRY	Region geograficzny (Northern/Southern/Western/Eastern Europe). Umożliwia analizę przestrzenną bez mapy.
SEASON	AGG_WEATHER_SEASONAL	Pora roku: Winter / Spring / Summer / Autumn. Wyliczana z miesiąca. Kluczowy filtr dla hipotezy klimatycznej.
IS_SEASONAL	DIM_DISORDER	BIT: 1 = zaburzenie o charakterze sezonowym (SAD). Umożliwia filtrowanie do zaburzeń wrażliwych na nasłonecznienie.
CATEGORY	DIM_DISORDER	Kategoria ICD-10 (Mood disorders, Anxiety disorders, Substance use itp.). Hierarchia: kategoria → konkretne zaburzenie.

7. Planowane raporty dla użytkowników

Dashboard Power BI składa się z pięciu stron tematycznych, umożliwiających analizę od poziomu ogólnoeuropejskiego do pojedynczego kraju i zaburzenia. Wszystkie strony współdzielą panel filtrów (kraj, rok, pora roku, typ klimatu).

Strona	Typ wizualizacji	Opis	Źródła danych
1. Mapa zdrowia psychicznego Europy	Filled Map (mapa Europy)	Intensywność kolorów = prevalencja wybranego zaburzenia. Drill-through do strony kraju. Filtry: rok, zaburzenie, kategoria ICD-10.	FACT_MENTAL_HEALTH + DIM_COUNTRY + DIM_YEAR

Strona	Typ wizualizacji	Opis	Źródła danych
2. Korelacja klimat–zdrowie	Scatter plot z linią trendu	Oś X: nasłonecznienie zimowe (AGG_WEATHER_SEASONAL, SEASON=Winter). Oś Y: PREVALENCE_PCT dla Depression/SAD. Punkt = kraj+rok. Współczynnik Pearsona.	AGG_WEATHER_SEASONAL + FACT_MENTAL_HEALTH
3. Trendy ekonomiczne i zdrowotne	Line chart z drill-down	Trend PREVALENCE_PCT i GDP w czasie 2000–2010. Drill-down: Europa → kraj → rok. Filtry: zaburzenie, region.	FACT_MENTAL_HEALTH + FACT_ECONOMY + DIM_YEAR
4. Bezrobocie, alkohol i zdrowie	Scatter plot + bar chart	Oś X = UNEMPLOYMENT_PCT, oś Y = ALCOHOL_LITERS_PER_CAPITA. Bar chart: prevalencja zaburzeń substancji per kraj.	FACT_ECONOMY + FACT_MENTAL_HEALTH
5. Analiza what-if: symulacja	Suwak parametru + DAX	Suwak: zmiana temperatury zimowej o X°C (-3 do +3). Miara DAX: wpływ na szacowaną prevalencję depresji (model regresji). Wykres: przed vs po per kraj.	AGG_WEATHER_SEASONAL + FACT_MENTAL_HEALTH (DAX what-if)